

# Метод наименьших квадратов и сингулярное разложение

Н. Н. Осипов

e-mail: nnosipov@rambler.ru

## Аннотация

Статья представляет собой более подробную версию открытой лекции, прочитанной автором в мае 2016 года студентам-первокурсникам специальности «Компьютерная безопасность».

I. Рассмотрим, вообще говоря, *переопределённую* систему линейных уравнений:

$$\sum_{j=1}^n a_{ij}x_j = b_i, \quad i = 1, \dots, m, \quad (0.1)$$

где  $m \geq n$ . Эту СЛУ можно записать в виде уравнения

$$\mathcal{A}(x) = b, \quad (0.2)$$

где  $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ ,  $b = (b_1, \dots, b_m) \in \mathbb{R}^m$  и

$$\mathcal{A} : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

— *линейное отображение*, заданное матрицей  $A = (a_{ij}) \in M_{m \times n}(\mathbb{R})$  в стандартных базисах арифметических векторных пространств  $\mathbb{R}^n$  и  $\mathbb{R}^m$ .<sup>1)</sup> Пусть

$$a_j = \mathcal{A}(e_j) \in \mathbb{R}^m, \quad j = 1, \dots, n,$$

— векторы, столбцы координат которых совпадают со столбцами матрицы  $A$ . Тогда уравнение (0.2) примет вид

$$x_1 a_1 + \dots + x_n a_n = b.$$

Для простоты далее будем считать, что отображение  $\mathcal{A}$  невырождено:

$$\text{Ker } \mathcal{A} = \{0\} \quad (0.3)$$

или, в других терминах, матрица  $A$  имеет полный ранг (система векторов  $(a_1, \dots, a_n)$  линейно независима). При  $m > n$  (и, тем более, при  $m \gg n$ , как часто бывает на практике) уравнение (0.2) обычно неразрешимо, ибо почти всегда вектор  $b$  не принадлежит подпространству

$$L = \text{Im } \mathcal{A} = \langle a_1, \dots, a_n \rangle.$$

Задача состоит в том, чтобы найти некоторое *псевдорешение*

$$x^0 = (x_1^0, \dots, x_n^0) \in \mathbb{R}^n$$

---

<sup>1)</sup>Напомним, что стандартным базисом арифметического  $n$ -мерного векторного пространства  $\mathbb{R}^n$  называется базис  $(e_1, \dots, e_n)$  из так называемых *единичных векторов* (все компоненты вектора  $e_j$  равны нулю, кроме  $j$ -й, которая равна 1).

уравнения (0.2) и тем самым как-то «решить» несовместную СЛУ (0.1).

Будем считать пространства  $\mathbb{R}^n$  и  $\mathbb{R}^m$  евклидовыми.<sup>2)</sup> В *методе наименьших квадратов* псевдорешение  $x^0 \in \mathbb{R}^n$  находят, исходя из следующего условия:

$$\min_{x \in \mathbb{R}^n} |b - \mathcal{A}(x)|^2 = |b - \mathcal{A}(x^0)|^2.$$

Это условие объясняет название самого метода, так как величина  $|b - \mathcal{A}(x)|^2$ , которую требуется минимизировать, есть сумма квадратов

$$\sum_{i=1}^m \left( b_i - \sum_{j=1}^n a_{ij} x_j \right)^2.$$

Метод наименьших квадратов широко применяется как в прикладной математике, так и в статистике.<sup>3)</sup>

Имеем  $b = b' + b''$ , где  $b' \in L$  — *ортгогональная проекция* вектора  $b$  на подпространство  $L$ , а  $b'' \in L^\perp$ . Пусть  $a = \mathcal{A}(x) = x_1 a_1 + \dots + x_n a_n \in L$ . Тогда по *теореме Пифагора*

$$|b - \mathcal{A}(x)|^2 = |b - a|^2 = |(b - b') + (b' - a)|^2 = |b - b'|^2 + |b' - a|^2 \geq |b - b'|^2,$$

причём равенство возможно только если  $a = b'$ . Итак, псевдорешение  $x^0$  должно удовлетворять уравнению

$$x_1 a_1 + \dots + x_n a_n = b'. \quad (0.4)$$

Из условия (0.3) следует, что это уравнение разрешимо и имеет единственное решение.

Стандартный теоретический способ решить уравнение (0.4) состоит в том, чтобы решить так называемую *нормальную СЛУ*

$$\sum_{j=1}^n (a_i, a_j) x_j = (a_i, b), \quad i = 1, \dots, n, \quad (0.5)$$

которая получится, если для каждого  $i = 1, \dots, n$  обе части уравнения (0.4) скалярно домножить на вектор  $a_i$  и учесть, что  $(a_i, b') = (a_i, b)$ . Матрица системы (0.5) есть *матрица Грама*

$$G = ((a_i, a_j)) = A^t A \in M_{n \times n}(\mathbb{R})$$

системы векторов  $(a_1, \dots, a_n)$ . Поскольку последняя является базисом подпространства  $L$ , имеем  $\det G > 0$ .<sup>4)</sup> Таким образом, псевдорешение  $x^0$  можно найти по формуле

$$\begin{bmatrix} x_1^0 \\ \vdots \\ x_n^0 \end{bmatrix} = G^{-1} A^t \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}. \quad (0.6)$$

<sup>2)</sup>Термин «евклидово пространство  $\mathbb{R}^n$ » в данном случае означает, что в пространстве  $\mathbb{R}^n$  задано стандартное скалярное произведение:

$$(x, y) = x_1 y_1 + \dots + x_n y_n,$$

где  $x = (x_1, \dots, x_n)$ ,  $y = (y_1, \dots, y_n)$ .

<sup>3)</sup>Подробнее см. по ссылке [3].

<sup>4)</sup>Действительно, пусть  $(w_1, \dots, w_n)$  — какой-нибудь ортонормированный базис  $L$ . Тогда  $G = T^t T$ , где  $T$  — *матрица перехода* от  $(w_1, \dots, w_n)$  к  $(a_1, \dots, a_n)$ . Следовательно,  $\det G = (\det T)^2 > 0$ .

**II.** Насколько хорош описанный выше способ отыскания псевдорешения с практической точки зрения?

Дело в том, что как матрица  $A$ , так и вектор  $b$  обычно заданы с какой-то погрешностью:

$$A \approx \hat{A}, \quad b \approx \hat{b}.$$

Возникает вопрос, насколько сильно может отличаться фактически вычисленное псевдорешение  $\hat{x}^0$ , соответствующее матрице  $\hat{A}$  и вектору  $\hat{b}$ , от истинного псевдорешения  $x^0$ .<sup>5)</sup>

В том, что применение формулы (0.6) на практике может оказаться небезобидным, показывает уже тривиальный случай  $m = n$ . В этом случае

$$G^{-1}A^t = (A^t A)^{-1}A^t = A^{-1},$$

и формула (0.6) упрощается до традиционной:

$$\begin{bmatrix} x_1^0 \\ \vdots \\ x_n^0 \end{bmatrix} = A^{-1} \begin{bmatrix} b_1 \\ \vdots \\ b_n \end{bmatrix}.$$

Проводить вычисления по этой формуле надёжнее, чем по формуле (0.6), поскольку лишние умножения матриц, вообще говоря, способствуют росту погрешности.

**III.** Опишем другой способ отыскания псевдорешения  $x^0$ , основанный на так называемом *сингулярном разложении* матрицы  $A$ , которое имеет вид

$$A = U\Sigma V^t. \quad (0.7)$$

Здесь  $U \in M_{m \times m}(\mathbb{R})$ ,  $V \in M_{n \times n}(\mathbb{R})$  — ортогональные матрицы,  $\Sigma \in M_{m \times n}(\mathbb{R})$  — диагональная прямоугольная матрица.<sup>6)</sup>

Объясним, как можно прийти к равенству (0.7). Рассмотрим линейный оператор

$$\mathcal{G} = \mathcal{A}^* \mathcal{A} : \mathbb{R}^n \rightarrow \mathbb{R}^n,$$

заданный матрицей  $G$  в стандартном базисе. Оператор  $\mathcal{G}$  является *самосопряжённым*, поскольку  $G^t = G$ . Следовательно, существует ортонормированный базис  $(v_1, \dots, v_n)$  пространства  $\mathbb{R}^n$ , состоящий из собственных векторов этого оператора:

$$\mathcal{G}(v_j) = \lambda_j v_j, \quad j = 1, \dots, n.$$

Этот базис называется *первым сингулярным базисом* матрицы  $A$ .<sup>7)</sup> Кроме того, имеем

$$\lambda_j = (v_j, \mathcal{G}(v_j)) = (v_j, \mathcal{A}^*(\mathcal{A}(v_j))) = (\mathcal{A}(v_j), \mathcal{A}(v_j)) = |\mathcal{A}(v_j)|^2 > 0$$

<sup>5)</sup>Отметим, что и сам процесс вычисления псевдорешения  $\hat{x}^0$  происходит с какой-то погрешностью (например, имеют место ошибки округления), которую также необходимо учитывать.

<sup>6)</sup>Напомним, что квадратная вещественная матрица  $C$  называется ортогональной, если  $C^{-1} = C^t$ . Подробнее о Singular Value Decomposition (SVD) и современных методах его нахождения см. по ссылке [4].

<sup>7)</sup>Или линейного отображения  $\mathcal{A}$ . Все результаты о сингулярном разложении можно излагать как на языке матриц, так и на языке линейных отображений (операторов).

для любого  $j = 1, \dots, n$ . Числа

$$\sigma_j = \sqrt{\lambda_j} = |\mathcal{A}(v_j)|, \quad j = 1, \dots, n,$$

называются *сингулярными числами* матрицы  $A$ . Далее положим

$$u_j = \frac{\mathcal{A}(v_j)}{\sigma_j}, \quad j = 1, \dots, n.$$

Система векторов  $(u_1, \dots, u_n)$  является ортонормированным базисом подпространства  $L$ :

$$(u_i, u_j) = \frac{1}{\sigma_i \sigma_j} (\mathcal{A}(v_j), \mathcal{A}(v_j)) = \frac{1}{\sigma_i \sigma_j} (v_i, \mathcal{G}(v_j)) = \frac{\lambda_j}{\sigma_i \sigma_j} (v_i, v_j) = \begin{cases} 1, & \text{если } i = j, \\ 0, & \text{если } i \neq j. \end{cases}$$

Дополним её до ортонормированного базиса  $(u_1, \dots, u_m)$  всего пространства  $\mathbb{R}^m$ . Он называется *вторым сингулярным* базисом матрицы  $A$ .

Теперь составим ортогональные матрицы  $U$  и  $V$  из столбцов координат векторов второго и первого сингулярных базисов соответственно, а диагональную матрицу  $\Sigma$  заполним сингулярными числами. Тогда

$$U\Sigma = AV$$

по построению, откуда, домножив справа на  $V^{-1} = V^t$ , получим (0.7).

Зная сингулярное разложение (0.7) матрицы  $A$ , псевдорешение  $x^0$  СЛУ (0.1) можно найти по формуле

$$x^0 = \sum_{j=1}^n \frac{(u_j, b)}{\sigma_j} v_j. \quad (0.8)$$

Для доказательства формулы (0.8) достаточно проверить, что она даёт решение уравнения (0.4). В самом деле, имеем

$$x_1^0 a_1 + \dots + x_n^0 a_n = \mathcal{A}(x^0) = \sum_{j=1}^n \frac{(u_j, b)}{\sigma_j} \mathcal{A}(v_j) = \sum_{j=1}^n (u_j, b) u_j = b'.$$

**IV.** Вернёмся к вопросу о погрешности при вычислении псевдорешения  $x^0$ , которая может возникнуть из-за того, что матрица  $A$  и вектора  $b$  сами заданы с некоторой погрешностью.

Для простоты будем считать, что матрица  $A$  задана точно ( $\hat{A} = A$ ), а возмущению подвергается только вектор  $b$ . Упорядочим сингулярные числа матрицы  $A$  по невозрастанию:

$$\sigma_1 \geq \dots \geq \sigma_n > 0.$$

Пусть теперь  $\hat{b} = b + \varepsilon u_n$ , где коэффициент  $\varepsilon$  — малое число. Из формулы (0.8) находим

$$\hat{x}^0 = x^0 + \frac{\varepsilon}{\sigma_n} v_n$$

при этом коэффициент  $\varepsilon/\sigma_n$  может оказаться существенным, если сингулярное число  $\sigma_n$  мало, а коэффициент  $\varepsilon$  соизмерим с  $\sigma_n$ . Таким образом, при практическом вычислении следует учитывать, что псевдорешение  $x^0$  будет особенно чувствительно к возмущениям вектора  $b$  вдоль

тех векторов второго сингулярного базиса матрицы  $A$ , которые соответствуют малым сингулярным числам.

Впрочем, практический интерес представляет оценка не абсолютной, а относительной погрешности вычисления  $x^0$ , а именно, сравнение последней с той относительной погрешностью, с которой задан вектор  $b$ . Пусть

$$\Delta = \frac{|\hat{x}^0 - x^0|}{|x^0|}, \quad \delta = \frac{|\hat{b} - b|}{|b|}.$$

С помощью формулы (0.8) нетрудно получить оценку

$$\frac{\Delta}{\delta} \leq \frac{|b|}{|b'|} \cdot \frac{|u'|}{|u|} \cdot \frac{\sigma_1}{\sigma_n},$$

где  $u = \hat{b} - b = u' + u''$  ( $u' \in L$ ,  $u'' \in L^\perp$ ). При  $b \in L$  и  $u \in L$  эта оценка упрощается до

$$\frac{\Delta}{\delta} \leq \frac{\sigma_1}{\sigma_n}.$$

Отношение  $\sigma_1/\sigma_n$  называется *числом обусловленности* матрицы  $A$  и обозначается  $\mu(A)$ .<sup>8)</sup> Ясно, что чем больше  $\mu(A)$ , тем более неустойчивым будет вычисление псевдорешения  $x^0$ .

Отметим, что сингулярное разложение матрицы  $G$  можно получить из сингулярного разложения (0.7) матрицы  $A$ . Оно имеет вид

$$G = V\Lambda V^t,$$

при этом на диагонали матрицы

$$\Lambda = \Sigma^t \Sigma \in M_{n \times n}(\mathbb{R})$$

находятся собственные числа  $\lambda_j = \sigma_j^2$  матрицы  $G$ . Поэтому  $\mu(G) = \mu(A)^2 \gg \mu(A)$ , если  $\mu(A)$  велико. Это значит, что в этом случае вычисление псевдорешения  $x^0$  по формуле (0.6) будет гораздо более неустойчивым, чем по формуле (0.8).

*Замечание.* 1. Подробное изложение различных практических способов поиска псевдорешений читатель может найти, например, в учебнике [1], глава IV. Там же (см. § 4 главы IV) можно узнать о применении метода наименьших квадратов в статистике (*линейная регрессия*).

2. При  $m = n$  из сингулярного разложения (0.7) матрицы  $A$  можно получить её *полярное разложение* (см. учебник [1], §§ 1 — 3 главы I) в виде

$$A = SR, \tag{0.9}$$

где  $S = U\Sigma U^t$ ,  $R = UV^t$ . Последние формулы также показывают, как от полярного разложения (0.9) матрицы  $A$  прийти к её сингулярному разложению.<sup>9)</sup>

<sup>8)</sup>Число  $\mu(A)$  естественным образом возникает при оценке относительной погрешности решения невырожденной системы линейных уравнений (см., например, [2], стр. 14).

<sup>9)</sup>Такая тесная связь между полярным и сингулярным разложениями матрицы неудивительна, поскольку конструкция обоих разложений основана на сингулярных базисах.

## Список литературы

- [1] *Беклемишев Д.В.* Дополнительные главы линейной алгебры. М.: Наука, 1983.
- [2] *Годунов С.К.* Решение систем линейных уравнений. Новосибирск: Наука, 1980.
- [3] [https://en.wikipedia.org/wiki/Linear\\_least\\_squares\\_\(mathematics\)](https://en.wikipedia.org/wiki/Linear_least_squares_(mathematics))
- [4] [https://en.wikipedia.org/wiki/Singular\\_value\\_decomposition](https://en.wikipedia.org/wiki/Singular_value_decomposition)